

Penerapan Recursive Forecasting dengan Strategi Cross-Station Proxy dan Adaptive Thresholding pada Peramalan ISPU Wilayah DKI Jakarta

Rafsanjani
Fakultas Ilmu Komputer
Universitas Indonesia
Depok, Indonesia
rafsanjani41@ui.ac.id

Muhammad Naufal Muzaki
Fakultas Ilmu Komputer
Universitas Indonesia
Depok, Indonesia
muhammad.naufal419@ui.ac.id

Marvel Irawan
Fakultas Ilmu Komputer
Universitas Indonesia
Depok, Indonesia
marvel.irawan@ui.ac.id

Intisari—Polusi udara merupakan ancaman lingkungan yang kritis di wilayah metropolitan, sehingga pengembangan sistem peramalan kualitas udara yang akurat menjadi esensial untuk mitigasi risiko kesehatan masyarakat. Penelitian ini bertujuan untuk membangun model *machine learning* tingkat lanjut guna memprediksi kategori Indeks Standar Pencemar Udara (ISPU), dengan fokus mengatasi tantangan *missing values* dan ketidakseimbangan data pada sensor pemantauan. Metodologi yang diusulkan menerapkan pendekatan hibrida yang mengintegrasikan data meteorologi dan indeks vegetasi (NDVI) melalui strategi *Recursive Forecasting* berbasis LightGBM. Kebaruan dalam penelitian ini terletak pada penerapan teknik *Cross-Station Proxy* untuk menyuntikkan dinamika fluktuasi lingkungan dari stasiun referensi, serta penggunaan *Adaptive Thresholding* untuk mengkalibrasi bias klasifikasi secara spesifik pada setiap lokasi pemantauan. Hasil eksperimen menunjukkan bahwa model yang dikembangkan mampu merekonstruksi pola musiman dan mendeteksi kejadian polusi ekstrem dengan performa yang lebih superior dibandingkan metode *baseline* klimatologi statis. Secara keseluruhan, penelitian ini memberikan kontribusi signifikan melalui kerangka kerja pemodelan yang adaptif dan *robust*, yang terbukti efektif dalam meningkatkan akurasi deteksi dini kondisi udara tidak sehat di tengah ketidakpastian data lingkungan yang dinamis.

Kata Kunci—Cross-Station Proxy, Adaptive Thresholding, LightGBM, Machine Learning, Polusi Udara, Recursive Forecasting, Climatology Imputation

I. PENDAHULUAN

Kualitas udara di kawasan metropolitan seperti DKI Jakarta menjadi isu lingkungan penting karena dampaknya terhadap kesehatan masyarakat dan keberlanjutan perkotaan. Di Indonesia, kondisi mutu udara ambien diukur menggunakan Indeks Standar Pencemar Udara (ISPU), yang merepresentasikan dampak kualitas udara berdasarkan konsentrasi tujuh parameter pencemar utama, yaitu PM₁₀, PM_{2.5}, NO₂, SO₂, CO, O₃, dan HC. Nilai ISPU ditetapkan dari parameter dengan tingkat pencemaran tertinggi pada suatu waktu. Mengingat dinamika polutan yang dipengaruhi oleh faktor meteorologi dan aktivitas manusia, diperlukan sistem pemantauan yang tidak hanya informatif secara real-time tetapi juga bersifat prediktif. Laporan ini membahas pengembangan sistem peramalan ISPU berbasis *machine learning*

untuk meningkatkan akurasi estimasi risiko polusi udara pada periode mendatang.

Latar Belakang. Pemantauan kualitas udara di Jakarta dihadapkan pada kendala reliabilitas sensor dan variabilitas musim yang memicu kekosongan data historis. Metode peramalan konvensional sering mengalami degradasi kinerja akibat ketidakmampuan menangani kompleksitas non-linear polutan dan akumulasi kesalahan jangka panjang (*error propagation*). Absennya mekanisme transfer informasi spasial juga menyebabkan kegagalan deteksi kejadian ekstrem (*outliers*), sehingga diperlukan pendekatan komputasi cerdas yang mampu mengintegrasikan variabel eksternal dan beradaptasi secara dinamis terhadap karakteristik spesifik setiap lokasi.

Tujuan, Manfaat, dan Kontribusi. Penelitian ini bertujuan untuk mengembangkan kerangka kerja peramalan ISPU harian yang presisi guna memitigasi risiko lingkungan pada periode kritis September hingga November 2025. Kontribusi teknis utama studi ini terletak pada integrasi strategi *Cross-Station Proxy*, yaitu mekanisme transfer informasi spasial yang memanfaatkan dinamika fluktuasi dari stasiun referensi untuk merekonstruksi pola data pada lokasi dengan reliabilitas sensor rendah. Pendekatan ini diperkuat melalui arsitektur *Hybrid Recursive Forecasting* berbasis LightGBM yang menggabungkan fitur historis *anchor* dengan variabel lingkungan eksternal untuk menjaga stabilitas prediksi jangka panjang. Sebagai penyempurnaan, penelitian ini memperkenalkan teknik kalibrasi pasca-pemrosesan adaptif yang secara otomatis menyesuaikan sensitivitas klasifikasi risiko polusi terhadap karakteristik distribusi unik di setiap titik pemantauan, sehingga mengurangi bias deteksi dini tanpa bergantung pada batasan statis konvensional.

Batasan. Lingkup penelitian ini difokuskan pada analisis deret waktu dari lima stasiun pemantauan utama di DKI Jakarta dengan memanfaatkan dataset historis periode 2010 hingga Agustus 2025 sebagai basis pelatihan model. Target peramalan dibatasi pada nilai maksimum harian ISPU secara agregat, tanpa menguraikan konsentrasi spesifik dari masing-masing parameter polutan penyusunnya. Validitas prediksi model bergantung pada asumsi *stationarity*, di mana pola

interaksi antara variabel meteorologi dan kualitas udara di masa lalu dianggap tetap relevan dan representatif untuk memproyeksikan dinamika lingkungan pada periode prediksi mendatang.

II. KAJIAN PUSTAKA

Integritas data merupakan prasyarat mutlak dalam pemodelan kualitas udara, namun kekosongan data (*missing values*) akibat kendala teknis sensor sering kali tidak terhindarkan. Norazian *et al.* (2008) melakukan investigasi mendalam mengenai efektivitas berbagai teknik imputasi tunggal untuk menangani data hilang pada parameter PM_{10} , dengan membandingkan metode imputasi rata-rata (*mean imputation*) dan teknik interpolasi. Temuan empiris mereka menunjukkan bahwa metode *mean-before-after*, yang mengestimasi nilai hilang berdasarkan rata-rata titik data terdekat sebelum dan sesudahnya, menghasilkan bias yang lebih rendah serta akurasi yang lebih tinggi dibandingkan imputasi rata-rata global. Studi ini memberikan justifikasi metodologis yang kuat bagi penelitian ini untuk memprioritaskan strategi imputasi berbasis urutan waktu (*temporal-based imputation*), seperti penerapan teknik *forward fill* dan *backward fill* yang dikelompokkan per stasiun, guna mempertahankan kontinuitas pola deret waktu yang krusial bagi kinerja algoritma peramalan.

Lebih jauh, untuk menangani ketergantungan temporal yang kompleks pada data kualitas udara, Biancofiore *et al.* (2017) mengajukan pendekatan berbasis *Recursive Neural Network* (RNN) untuk memprediksi konsentrasi partikulat PM_{10} dan $PM_{2.5}$ di wilayah pesisir Italia. Penelitian tersebut menunjukkan bahwa arsitektur rekursif, yang memiliki mekanisme umpan balik untuk menyimpan memori jangka pendek dari input historis, mampu memodelkan dinamika non-linear polusi udara dengan akurasi yang lebih tinggi dibandingkan metode statistik konvensional seperti *Multiple Linear Regression* (MLR). Temuan ini memberikan landasan konseptual yang kuat bagi penerapan strategi *Recursive Forecasting* dalam penelitian ini, di mana hasil prediksi sebelumnya dimanfaatkan secara iteratif sebagai fitur masukan untuk menjaga kontinuitas tren pada horizon peramalan jangka panjang.

Dalam konteks spesifik wilayah studi DKI Jakarta, Suhendi *et al.* (2026) melakukan analisis komparatif terhadap kinerja empat algoritma *machine learning*, yaitu *Support Vector Machine* (SVM), *Gradient Boosting*, *Random Forest*, dan *Decision Tree*, dengan menggunakan data ISPU periode Januari hingga November 2024. Hasil empiris menunjukkan bahwa metode berbasis *ensemble* secara konsisten mengungguli pendekatan lainnya, di mana *Random Forest* mencapai akurasi tertinggi sebesar 93,71%, diikuti oleh *Decision Tree* (93,41%) dan *Gradient Boosting* (92,81%), sementara SVM menunjukkan kinerja terendah. Studi ini menegaskan bahwa algoritma berbasis pohon keputusan (*tree-based*) memiliki kemampuan yang lebih unggul dalam memodelkan pola polusi udara lokal dibandingkan metode berbasis *hyperplane*. Kesimpulan tersebut memberikan landasan empiris yang kuat bagi penelitian ini untuk mengadopsi LightGBM sebagai evo-

lusi efisien dari teknik *gradient boosting* dalam menangani kompleksitas karakteristik data kualitas udara di Jakarta.

III. METODOLOGI

A. Dataset

Penelitian ini menggunakan dataset historis kualitas udara harian DKI Jakarta periode 1 Januari 2010 hingga 31 Agustus 2025 dari lima Stasiun Pemantauan Kualitas Udara (SPKU): Bundaran HI, Kelapa Gading, Jagakarsa, Lubang Buaya, dan Kebon Jeruk. Data target mencakup Indeks Standar Pencemar Udara (ISPU) yang dihitung dari enam polutan kriteria (PM_{10} , $PM_{2.5}$, SO_2 , CO , O_3 , NO_2) beserta kategori kesehatan udara.

Untuk menangkap heterogenitas spasial dan dinamika atmosfer mikro, dataset ini diperkaya dengan dua fitur eksternal: (1) *Normalized Difference Vegetation Index* (NDVI) beresolusi 16 hari sebagai proksi vegetasi (*natural sink*), dan (2) data meteorologi beresolusi jam (*hourly*) untuk merekam fluktuasi intra-harian yang memengaruhi dispersi polutan. Ringkasan seluruh variabel penelitian disajikan secara terpadu pada Tabel I.

TABLE I: Ringkasan Variabel Penelitian (ISPU, Meteorologi, dan Vegetasi)

Kategori	Variabel	Deskripsi/Satuan	Resolusi
Kualitas Udara	PM_{10} , $PM_{2.5}$	Partikulat ($\mu g/m^3$)	Harian
	SO_2 , CO	Gas Polutan ($\mu g/m^3$)	Harian
	O_3 , NO_2	Gas Polutan ($\mu g/m^3$)	Harian
	ISPU Max	Nilai Indeks Tertinggi	Harian
	Kategori	Kelas (Baik s.d Berbahaya)	Harian
Meteorologi	Temperatur	Rata-rata, Min, Max ($^{\circ}C$)	Per Jam
	Kelembaban	Relative Humidity (%)	Per Jam
	Tekanan	Tekanan Atmosfer (hPa)	Per Jam
	Angin	Kecepatan (m/s) & Arah ($^{\circ}$)	Per Jam
Geospasial	NDVI	Indeks Vegetasi	16-Hari

B. Pra-pemrosesan Data

Serangkaian tahapan pra-pemrosesan diterapkan untuk menjamin konsistensi data sebelum pemodelan, mencakup penanganan format, resolusi waktu, dan data hilang.

Pembersihan Data dan Standardisasi Label. Tahap awal memvalidasi tipe data dan menyederhanakan target klasifikasi. Seluruh fitur polutan numerik dibersihkan dari nilai non-valid (*noise*), sementara label kategori ekstrem (*Sangat Tidak Sehat* dan *Berbahaya*) digabungkan ke dalam kelas *Tidak Sehat*. Strategi penggabungan ini diterapkan untuk memitigasi ketidakseimbangan kelas (*class imbalance*) yang ekstrem, namun tetap mempertahankan representasi risiko kesehatan yang signifikan dalam dataset.

Interpolasi NDVI. Untuk menyelaraskan resolusi temporal data NDVI (16 hari) dengan data harian ISPU, diterapkan metode *time-based linear interpolation*. Proses ini dilakukan secara independen pada masing-masing stasiun (DKI1–DKI5). Pendekatan ini mengisi kekosongan data harian dengan mempertimbangkan gradien waktu, memastikan kontinuitas tren vegetasi tetap terjaga saat digabungkan dengan data polutan.

Penanganan Missing Values. Strategi hibrida digunakan untuk menangani data hilang seperti yang ditunjukkan pada Gambar 1. Pertama, observasi tanpa atribut krusial (tanggal dan lokasi) dihapus (*listwise deletion*). Kedua, nilai hilang pada fitur polutan diimputasi menggunakan nilai median yang dikelompokkan secara hierarkis berdasarkan lokasi, bulan, dan hari. Penggunaan estimator median dipilih karena sifatnya yang robust terhadap pencilan (*outliers*), sekaligus memastikan nilai pengganti tetap merepresentasikan variabilitas musiman lokal.




Fig. 1: Distribusi Missing Value

C. Analisis Data Eksplorasi

Ketidakseimbangan Distribusi Kategori. Ketika kita mencoba melihat distribusi kategori ISPU pada dataset yang sudah dilakukan pra-pemrosesan dan pembersihan, seperti yang terlihat pada Fig. 2, mengungkapkan adanya disparitas yang tajam pada distribusi kelas kualitas udara. Kategori




Fig. 2: Distribusi frekuensi kategori ISPU

Sedang mendominasi dataset secara signifikan dengan total 10.448 sampel (sekitar 68% dari keseluruhan data), yang merefleksikan karakteristik kualitas udara Jakarta yang cenderung berada pada tingkat moderat. Sebaliknya, kategori

Baik dan *Tidak Sehat* memiliki frekuensi kejadian yang relatif lebih rendah, masing-masing sebanyak 2.342 dan 2.622 sampel. Ketimpangan distribusi kelas (*imbalanced dataset*) ini menunjukkan tantangan pemodelan yang krusial, karena algoritma *machine learning* konvensional berpotensi mengalami bias prediksi yang condong ke kelas mayoritas, yaitu *Sedang*.

Analisis Statistik Deskriptif. Analisis terhadap properti statistik fitur numerik polutan dilakukan untuk memahami karakteristik sebaran data serta mengidentifikasi potensi anomali distribusi.

TABLE II: Statistik Deskriptif Dataset ISPU

Var.	Mean	Std	Min	P25	Med	P75	Max
PM ₁₀	54.10	18.95	2.00	42.00	55.00	65.00	187.00
PM _{2.5}	75.86	24.13	10.00	60.00	77.00	91.00	287.00
SO ₂	27.91	15.59	0.00	15.00	26.00	39.00	112.00
CO	20.30	12.19	0.00	11.00	18.00	26.00	134.00
O ₃	53.45	40.57	2.00	25.00	42.00	71.00	314.00
NO ₂	17.28	11.56	0.00	10.00	15.00	22.00	202.00
ISPU Max	78.02	33.19	5.00	57.00	73.00	92.00	314.00

Ringkasan statistik deskriptif yang disajikan pada Tabel II menunjukkan adanya variabilitas yang signifikan antar-parameter. Fitur PM₁₀ dan PM_{2.5} memiliki nilai *skewness* yang relatif rendah, masing-masing sebesar 0,28 dan 0,22, yang mengindikasikan distribusi data yang mendekati normal atau relatif simetris. Sebaliknya, parameter gas seperti NO₂, O₃, dan CO menunjukkan nilai *skewness* yang tinggi (lebih besar dari 1,5) serta nilai *kurtosis* yang ekstrem, khususnya pada NO₂ dengan nilai 11,90. Karakteristik ini mengonfirmasi keberadaan *heavy tails* atau ekor distribusi panjang ke arah kanan, yang merepresentasikan kejadian polusi ekstrem yang jarang terjadi namun berdampak signifikan.

Lebih lanjut, visualisasi histogram yang dilengkapi dengan estimasi densitas kernel (*Kernel Density Estimation*) pada Gambar 3 memperjelas pola distribusi tersebut. Mayoritas fitur memperlihatkan distribusi dengan *positive skewness*, di mana sebagian besar massa data terkonsentrasi pada nilai rendah yang merepresentasikan kualitas udara baik hingga sedang, namun disertai keberadaan *outliers* pada nilai tinggi. Fenomena ini memberikan implikasi penting bagi proses pemodelan, yaitu bahwa model yang dikembangkan harus bersifat robust terhadap pencilan agar tidak mengalami bias pada kejadian ekstrem. Selain itu, penggunaan metrik evaluasi berbasis kuadrat seperti RMSE berpotensi sangat dipengaruhi oleh nilai ekstrem, sehingga diperlukan pertimbangan penggunaan metrik alternatif seperti MAE atau penerapan transformasi data untuk memperoleh evaluasi performa yang lebih representatif.

Analisis Korelasi Matriks. Analisis korelasi Pearson dilakukan untuk memetakan hubungan linear antar-variabel serta mengidentifikasi fitur yang paling berpengaruh terhadap penentuan kategori kualitas udara, sebagaimana divisualisasikan melalui *heatmap* pada Gambar 4. Hasil analisis menunjukkan bahwa PM_{2.5} memiliki korelasi yang sangat kuat dengan nilai *max* ISPU ($r = 0,96$) dan korelasi absolut tertinggi terhadap target kategori ($|r| = 0,77$), mengindikasikan per-




Fig. 3: Distribusi Polutan

annya sebagai polutan dominan dan parameter kritis utama di wilayah DKI Jakarta.




Fig. 4: Korelasi Matriks

Selain itu, ditemukan korelasi positif yang signifikan antara PM_{10} dan $PM_{2.5}$ ($r = 0,77$), yang mencerminkan kesamaan sumber emisi kedua partikulat tersebut. Meskipun menunjukkan multikolinearitas, kondisi ini umumnya dapat ditangani dengan baik oleh model berbasis pohon keputusan seperti LightGBM. Di luar partikulat, ozon permukaan (O_3) juga menunjukkan korelasi yang cukup kuat terhadap nilai max ($r = 0,74$), menegaskan perannya sebagai polutan sekunder yang relevan. Sebaliknya, parameter gas lain seperti SO_2 , NO_2 , dan CO memiliki korelasi yang relatif rendah ($r < 0,4$), sehingga kontribusinya terhadap penentuan ISPU cenderung lebih terbatas dibandingkan polutan partikulat.

Analisis Tren ISPU per Lokasi. Evaluasi terhadap evolusi kualitas udara jangka panjang pada periode 2010–2025 di lima stasiun pemantauan, sebagaimana ditunjukkan pada Gambar 5, mengungkapkan adanya heterogenitas spasial yang signifikan di wilayah DKI Jakarta. Garis tren regresi linear (ditandai dengan garis merah putus-putus) memperlihatkan perbedaan pola yang jelas antar-lokasi. Stasiun DKI2 (Kelapa Gading) dan DKI3 (Jagakarsa) menunjukkan kecenderungan penurunan kategori ISPU yang mengindikasikan adanya perbaikan kualitas udara secara bertahap. Sebaliknya, stasiun DKI4 (Lubang Buaya) menampilkan tren positif

yang merefleksikan peningkatan tingkat polusi, yang diduga dipengaruhi oleh faktor-faktor lokal seperti aktivitas industri maupun kedekatan dengan simpul transportasi berintensitas emisi tinggi.




Fig. 5: Tren ISPU per Lokasi

Disparitas tren antar-stasiun tersebut menegaskan bahwa polusi udara di Jakarta tidak bersifat seragam, melainkan sangat dipengaruhi oleh kondisi mikroklimat dan pola tata guna lahan setempat. Temuan ini memberikan justifikasi empiris yang kuat bagi strategi pemodelan yang memasukkan identitas lokasi pemantauan (*lokasi_spk*) serta fitur lingkungan lokal, seperti NDVI, sebagai prediktor utama untuk menangkap variabilitas karakteristik kualitas udara yang unik pada setiap wilayah.

Selain tinjauan jangka panjang, analisis pola musiman tahunan juga dilakukan untuk memvalidasi konsistensi perilaku polutan antar-tahun. Gambar 6 menyajikan perbandingan data aktual ISPU tahun 2025 terhadap pola tahun 2024 di kelima stasiun pemantauan. Visualisasi ini mengungkapkan adanya siklus musiman yang kuat, di mana tingkat polusi cenderung lebih rendah pada awal tahun (Januari–April) yang berasosiasi dengan musim penghujan dan mekanisme *wet deposition*, kemudian meningkat secara signifikan memasuki pertengahan tahun (Mei–September) seiring datangnya musim kemarau.

Secara umum, data tahun 2025 (garis biru) menunjukkan keselarasan pola dengan tahun 2024 (garis merah putus-putus), meskipun terdapat variasi intensitas harian. Fenomena ini mengonfirmasi bahwa variabel meteorologis musiman memiliki pengaruh deterministik terhadap kualitas udara Jakarta. Pengecualian terlihat pada stasiun DKI3 (Jagakarsa) yang menunjukkan fluktuasi yang lebih landai dibanding stasiun lainnya, mengindikasikan karakteristik lingkungan yang lebih hijau atau jarak yang lebih jauh dari sumber emisi primer. Konsistensi pola musiman ini memperkuat urgensi penggunaan fitur berbasis waktu (*time-based features*) seperti bulan atau hari dalam tahun (*day of year*) pada tahap pemodelan prediktif.

D. Rekayasa Fitur (Feature Engineering)

Untuk meningkatkan kemampuan model dalam menangkap pola meteorologis yang kompleks, dilakukan proses rekayasa fitur melalui tiga pendekatan utama, yaitu proyeksi vektor fisik, agregasi statistik intra-harian, serta integrasi konteks temporal jangka panjang.

Transformasi Vektor Angin. Data arah angin mentah dalam satuan derajat memiliki sifat siklis yang berpotensi menyempitkan model numerik, di mana sudut 0° dianggap




Fig. 6: Validasi Pola Musiman ISPU: Perbandingan Data 2024 dan 2025 di Lima Stasiun

berjauhan dari 359° meskipun secara fisik berdekatan. Untuk mengatasi permasalahan tersebut, fitur kecepatan dan arah angin pada ketinggian 10 m dan 100 m ditransformasikan ke dalam komponen vektor ortogonal pada sumbu x dan y . Transformasi ini dilakukan menggunakan persamaan proyeksi sebagai berikut:

$$u = ws \cdot \cos(\theta_{rad}), \quad v = ws \cdot \sin(\theta_{rad}), \quad (1)$$

di mana ws merepresentasikan kecepatan angin dan θ_{rad} menyatakan arah angin dalam satuan radian. Proses ini menghasilkan empat fitur baru yang lebih representatif secara spasial, yaitu u_{10m} , v_{10m} , u_{100m} , dan v_{100m} .




Fig. 7: Perbandingan distribusi fitur angin tanpa dan dengan FE

Ekstraksi Dinamika Intra-Harian dan Agregasi Statistik. Sebelum data dianalisis dalam resolusi harian, dinamika fluktuasi pada data meteorologi per jam diekstraksi terlebih

dahulu. Fitur variasi temporal dibentuk dengan menghitung nilai delta, yaitu selisih setiap variabel terhadap nilainya sendiri pada rentang lag -4 hingga $+4$ jam. Pendekatan ini bertujuan untuk merekam laju perubahan (*rate of change*) kondisi atmosfer jangka pendek. Selanjutnya, seluruh informasi mikro tersebut diringkas menjadi satu representasi data harian melalui agregasi statistik yang mencakup nilai minimum, maksimum, rata-rata, dan simpangan baku. Dengan cara ini, volatilitas cuaca sepanjang hari tetap terenkapsulasi dalam fitur harian yang digunakan oleh model.

Integrasi Referensi Klimatologi dan Tren Historis.

Untuk membantu model membedakan kondisi normal dan anomali cuaca, fitur harian diperkaya dengan data referensi klimatologi yang berfungsi sebagai nilai jangkar (*anchor*) historis pada setiap lokasi pemantauan. Mengingat adanya ketidaklengkapan data historis, diterapkan mekanisme imputasi bertingkat, di mana nilai yang hilang terlebih dahulu diisi menggunakan median spesifik lokasi, dan jika masih kosong, digantikan dengan median global. Selain konteks jangka panjang, dinamika tren jangka pendek ditangkap melalui fitur *lag* harian serta statistik *rolling window* selama tujuh hari. Hasil eksperimen menunjukkan bahwa fitur *rolling window* berperan penting dalam meningkatkan stabilitas konvergensi dan akurasi model, karena mampu merangkum momentum perubahan tingkat polusi dalam rentang waktu satu minggu terakhir.

E. Cross-Station Proxy

Pada penelitian ini diperkenalkan strategi injeksi *Cross-Station Proxy* yang berlandaskan prinsip Tobler dalam geografi, yaitu bahwa lokasi yang berdekatan cenderung memiliki kemiripan karakteristik lingkungan yang lebih tinggi dibandingkan lokasi yang berjauhan. Mekanisme ini bekerja dengan mensubstitusi fitur meteorologi yang hilang atau tidak tersedia pada stasiun target (S_{target}) menggunakan data dari stasiun donor (S_{proxy}) yang memiliki kemiripan spasiotemporal tertinggi.

Pemilihan stasiun proxy dilakukan secara sistematis melalui analisis matriks korelasi Pearson terhadap data historis antar-stasiun. Stasiun donor ditentukan berdasarkan fungsi maksimasi kesamaan sebagai berikut:

$$S_{proxy}^{(i)} = \arg \max_{j \in S, j \neq i} \rho(X_{meteo}^{(i)}, X_{meteo}^{(j)}), \quad (2)$$

di mana $\rho(\cdot)$ menyatakan koefisien korelasi Pearson, $X_{meteo}^{(i)}$ adalah vektor fitur meteorologi pada stasiun target ke- i , dan S merepresentasikan himpunan seluruh stasiun pemantauan.

Penerapan teknik ini memberikan dua keuntungan strategis bagi arsitektur model. Pertama, *stabilitas inferensi*, yaitu menjamin model tetap mampu menghasilkan prediksi ISPU meskipun data cuaca pada stasiun utama terputus dengan memanfaatkan informasi dari stasiun tetangga yang valid. Kedua, *augmentasi data*, di mana selama proses pelatihan pendekatan ini bertindak sebagai bentuk regularisasi yang mendorong model mempelajari pola cuaca regional (makro), sehingga mengurangi risiko *overfitting* terhadap mikroklimat spesifik pada satu stasiun tertentu.

F. Arsitektur Peramalan Rekursif (Recursive Forecasting Framework)

Untuk menangani tantangan peramalan multi-langkah, yaitu memprediksi hingga H hari ke depan, penelitian ini mengadopsi strategi *Recursive Multi-step Forecasting*. Berbeda dengan pendekatan *Direct Strategy* yang melatih model terpisah untuk setiap horizon waktu, pendekatan rekursif memanfaatkan satu model tunggal $f(\cdot)$ yang dilatih untuk melakukan prediksi satu langkah ke depan ($t + 1$). Prediksi yang dihasilkan kemudian diumpankan kembali (*fed back*) sebagai fitur *lag* untuk memprediksi langkah berikutnya ($t + 2$), dan proses ini diulang secara iteratif hingga mencapai horizon prediksi yang diinginkan.

Pemilihan arsitektur ini didasarkan pada temuan Biancofiore *et al.* (2017), yang menunjukkan bahwa mekanisme rekursif memiliki keunggulan dalam memodelkan dinamika polutan udara yang bersifat non-linear serta memiliki ketergantungan temporal yang kuat. Dalam konteks data ISPU, konsentrasi polutan pada hari berikutnya sangat dipengaruhi oleh kondisi pada hari sebelumnya. Dengan memperbarui fitur *lag* secara dinamis menggunakan hasil prediksi terdahulu, model mampu mempertahankan kontinuitas tren dan struktur autokorelasi data, yang sering kali tidak tertangkap oleh pendekatan statistik konvensional.

Secara matematis, jika $\hat{y}_{t+h}$ menyatakan nilai prediksi pada horizon ke- h dan $\mathbf{x}_{t+h}$ merepresentasikan vektor fitur eksogen (misalnya variabel meteorologi) yang diasumsikan telah diketahui atau diinjeksi melalui mekanisme proxy, maka proses peramalan rekursif dapat dirumuskan sebagai berikut:

$$\hat{y}_{t+1} = f(y_t, y_{t-1}, \dots, \mathbf{x}_{t+1}), \quad (3)$$

$$\hat{y}_{t+2} = f(\hat{y}_{t+1}, y_t, \dots, \mathbf{x}_{t+2}), \quad (4)$$

$$\vdots$$

$$\hat{y}_{t+h} = f(\hat{y}_{t+h-1}, \hat{y}_{t+h-2}, \dots, \mathbf{x}_{t+h}). \quad (5)$$

Implementasi algoritma ini dirancang menggunakan mekanisme *sliding window* otomatis yang memperbarui seluruh fitur turunan pada setiap iterasi prediksi, termasuk statistik *rolling window* dan fitur *lag*. Dengan pendekatan ini, konsistensi struktur temporal data tetap terjaga sepanjang horizon peramalan. Rincian algoritma dan logika komputasi terdapat dalam Algoritma 1.

Algorithm 1 Recursive Multi-step Forecasting

Require: Model terlatih M , data historis D , horizon H , fitur eksogen F

Ensure: Prediksi $P = [\hat{y}_{t+1}, \dots, \hat{y}_{t+H}]$

```

1: Inisialisasi  $P \leftarrow []$ 
2: for  $h = 1$  to  $H$  do
3:   Bangun fitur dari  $D$  dan  $F[h]$ 
4:    $\hat{y}_{t+h} \leftarrow M.predict(\cdot)$ 
5:   Tambahkan  $\hat{y}_{t+h}$  ke  $D$  dan  $P$ 
6: end for
7: return  $P$ 
```

G. Kalibrasi Pasca-Pemrosesan

Mengingat model peramalan cenderung menghasilkan prediksi yang bersifat konservatif (*mean-reverting*), di mana

nilai keluaran berkumpul di sekitar rata-rata dan kurang responsif terhadap nilai ekstrem, maka keluaran mentah dari model rekursif memerlukan tahap kalibrasi akhir. Tahap pasca-pemrosesan ini bertujuan untuk menyelaraskan distribusi prediksi dengan batasan fisik lingkungan sekaligus meningkatkan akurasi klasifikasi kategori ISPU. Strategi yang diterapkan terdiri atas dua mekanisme utama sebagai berikut.

Penegakan Batasan Fisik (Physical Constraint Enforcement). Langkah pertama difokuskan pada penjaminan validitas fisik dari nilai prediksi ISPU. Model regresi berbasis pohon keputusan, seperti *gradient boosting*, dalam kondisi tertentu dapat menghasilkan proyeksi nilai negatif atau nilai yang tidak masuk akal secara fisik akibat ekstrapolasi tren menurun yang ekstrem. Untuk mencegah hal tersebut, diterapkan fungsi *clipping* yang membatasi ruang solusi prediksi sebagai berikut:

$$\hat{y}_{\text{final}} = \max(0, \hat{y}_{\text{raw}}), \quad (6)$$

sehingga seluruh nilai prediksi yang diteruskan ke tahap evaluasi tetap berada dalam domain yang valid secara logis dan fisik.

Optimisasi Ambang Batas Adaptif (Adaptive Threshold Optimization). Dalam regulasi standar, konversi nilai numerik ISPU ke dalam kategori kualitas udara (Baik, Sedang, Tidak Sehat, dan seterusnya) dilakukan menggunakan ambang batas yang bersifat statis. Namun, model *machine learning* sering kali memiliki bias sistematis, misalnya memprediksi nilai yang sedikit lebih rendah dari kondisi aktual pada kejadian polusi tinggi. Jika ambang batas regulasi diterapkan secara langsung, kondisi tersebut berpotensi menghasilkan kesalahan tipe II (*false negatives*) yang berdampak signifikan terhadap metrik evaluasi berbasis kelas minoritas, seperti *Macro F1-score*.

Untuk mengatasi permasalahan tersebut, penelitian ini menerapkan strategi *adaptive thresholding* menggunakan teknik pencarian grid (*grid search*). Alih-alih menggunakan batas regulasi yang kaku, dicari himpunan ambang optimal θ^* pada data validasi yang memaksimalkan skor *Macro F1*. Secara formal, permasalahan ini dirumuskan sebagai:

$$\theta^* = \arg \max_{\theta \in [T_{\min}, T_{\max}]} (\text{MacroF1}(y_{\text{val}}, f_{\text{class}}(\hat{y}_{\text{val}}, \theta))), \quad (7)$$

di mana f_{class} merupakan fungsi pemetaan nilai numerik prediksi ke kategori kualitas udara berdasarkan kandidat ambang θ . Pendekatan ini memungkinkan batas keputusan (*decision boundary*) bergeser secara adaptif mengikuti karakteristik distribusi keluaran model. Sebagai ilustrasi, ambang kategori *Tidak Sehat* dapat bergeser dari nilai regulasi 101 menjadi 95, sehingga model menjadi lebih sensitif terhadap kejadian polusi tinggi dan mampu menekan tingkat kesalahan *false negative*.

H. Metrik Evaluasi

Kinerja model dievaluasi menggunakan kombinasi metrik regresi dan klasifikasi untuk menilai kualitas prediksi numerik ISPU sekaligus ketepatan klasifikasi kategori kualitas

udara. Metrik yang digunakan meliputi *Mean Absolute Error* (MAE), *Accuracy*, dan *Macro F1-score*. Di antara metrik tersebut, *Macro F1-score* ditetapkan sebagai metrik evaluasi utama karena paling sesuai untuk karakteristik dataset yang tidak seimbang.

Mean Absolute Error (MAE). MAE mengukur rata-rata selisih absolut antara nilai prediksi dan nilai aktual ISPU, sehingga memberikan gambaran langsung mengenai besarnya kesalahan prediksi secara rata-rata:

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|. \quad (8)$$

Metrik ini mudah diinterpretasikan dan relatif robust terhadap penciliran ekstrem.

Accuracy. Accuracy merepresentasikan proporsi prediksi kategori yang benar terhadap seluruh observasi:

$$\text{Accuracy} = \frac{\sum_{i=1}^N \mathbb{I}(y_i = \hat{y}_i)}{N}, \quad (9)$$

dengan $\mathbb{I}(\cdot)$ sebagai fungsi indikator. Meskipun intuitif, metrik ini kurang representatif pada kondisi distribusi kelas yang tidak seimbang karena cenderung didominasi oleh kelas mayoritas.

Macro F1-score. *Macro F1-score* dipilih sebagai metrik evaluasi utama dalam penelitian ini. F1-score untuk setiap kelas k dihitung sebagai rata-rata harmonik antara *precision* dan *recall*:

$$\text{F1}_k = \frac{2 \cdot \text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k}. \quad (10)$$

Selanjutnya, *Macro F1-score* diperoleh dengan meratakan F1-score dari seluruh kelas:

$$\text{Macro F1} = \frac{1}{K} \sum_{k=1}^K \text{F1}_k, \quad (11)$$

dengan K menyatakan jumlah kelas. Dengan memberikan bobot yang sama pada setiap kelas, metrik ini mampu mengevaluasi performa model secara adil pada kelas mayoritas maupun minoritas. Oleh karena itu, *Macro F1-score* sangat relevan untuk menilai kemampuan model dalam mendeteksi kondisi kualitas udara berisiko tinggi, yang memiliki implikasi penting dalam konteks mitigasi kesehatan masyarakat.

IV. ANALISIS HASIL DAN PEMBAHASAN

A. Perbandingan Performa Eksperimental

Untuk mendapatkan model terbaik, kami melakukan pengujian ekstensif menggunakan berbagai strategi rekayasa fitur (*feature engineering*) dan pendekatan *forecasting*. Evaluasi difokuskan pada metrik **Macro F1-Score** mengingat ketidakseimbangan kelas (*imbalance data*) yang ekstrem pada dataset ISPU, di mana deteksi kategori "TIDAK SEHAT" (minoritas) merupakan prioritas utama sistem peringatan dini.

Ringkasan performa dari seluruh metode eksperimen disajikan pada Tabel III.

TABLE III: Rekapitulasi Performa Model Eksperimen pada Data Validasi (Periode: 1 Sept – 30 Nov 2024)

Strategi / Konfigurasi Model	Macro F1	Acc	MAE
A. Baseline Models (Imputation & Recursive):			
M1: RF + Climatology Imputation	0.3281	0.78	17.51
M2: LGBM + Climatology Imputation	0.3139	0.89	13.19
M3: RF + Recursive Forecast	0.2957	0.70	20.08
M4: LGBM + Recursive Forecast	0.4243	0.69	21.41
B. Advanced Feature Engineering (LGBM Base):			
M5: LGBM + Hourly Weather/NDVI	0.4280	0.77	17.75
↪ w/ Adaptive Threshold	0.5073	0.86	-
M6: M5 + Historical Climatology	0.3700	0.88	15.25
↪ w/ Adaptive Threshold	0.5300	0.90	-
M7: M6 + Shift 11 Bulan	0.5100	0.81	16.84
↪ w/ Adaptive Threshold	0.5700	0.86	-
M8: M6 + Shift 340 Hari	0.4900	0.79	17.08
↪ w/ Adaptive Threshold	0.5500	0.83	-
M9: M8 + Cross-Station Ens	0.4700	0.71	19.35
↪ w/ Adaptive Threshold	0.5700	0.86	-

Catatan: Tanda (-) pada MAE baris Adaptive Threshold menunjukkan nilai error prediksi regresi sama dengan model induknya.

1) *Analisis Trade-off Akurasi vs F1-Score:* Berdasarkan Tabel III, terjadi fenomena menarik di mana model **LGBM + Climatology Imputation** (M2) mencatatkan Akurasi tertinggi (0.89) dan error terendah (MAE 13.19), namun memiliki Macro F1 yang sangat rendah (0.3139). Hal ini mengindikasikan model tersebut mengalami *overfitting* terhadap kelas mayoritas ("SEDANG") dan gagal mendeteksi lonjakan polusi berbahaya.

Sebaliknya, strategi **M9 (LGBM + Cross-Station Ensemble)** dengan teknik *Adaptive Thresholding* menghasilkan performa paling optimal. Metode ini mencapai **Macro F1 tertinggi (0.57)** dengan akurasi yang tetap tinggi (0.86). Penggunaan fitur *ensemble* dari stasiun sekitar terbukti membuat model lebih *robust* dalam mengenali pola polusi regional dibandingkan hanya mengandalkan data historis satu stasiun.

B. Evaluasi pada Data Uji Publik (Generalisasi Model)

Temuan menarik diperoleh ketika model terbaik (M9) dievaluasi pada *unseen test data* (Public Leaderboard, yang mana 30% dari *test data*). Model mencatatkan peningkatan performa yang signifikan, dari **Macro F1 0.57** pada fase validasi menjadi **0.68** pada pengujian publik. Disparitas positif ini (+0.11) mengindikasikan dua hal krusial:

- 1) **Validasi Konservatif (Pessimistic Validation):** Periode validasi yang dipilih (1 September – 30 November 2024) merupakan masa transisi musim (*Pancaroba*) di Jakarta, yang ditandai dengan instabilitas atmosfer tinggi dan pola hujan yang acak. Kondisi ini memberikan tantangan "terberat" bagi model selama pelatihan. Kemampuan model untuk beradaptasi pada periode sulit ini membuatnya sangat *robust* ketika menghadapi data uji yang mungkin memiliki pola musiman yang lebih stabil.
- 2) **Efektivitas Regularisasi dan Fitur Spasial:** Peningkatan skor pada data publik mengonfirmasi bahwa model tidak mengalami *overfitting*. Strategi *Cross-*

Station Ensemble terbukti sukses menangkap sinyal polusi regional yang bersifat universal, bukan sekadar menghafal *noise* lokal pada data latih. Hal ini menunjukkan bahwa model memiliki kapabilitas generalisasi (*generalization power*) yang sangat baik untuk memprediksi kualitas udara di luar periode pelatihan.

C. Detail Performa StModel Terbaik (Metode 9)

Berikut adalah detail performa klasifikasi untuk model terpilih, yaitu **M9 (LGBM + Cross-Station Ensemble + Adaptive Threshold)** pada set validasi:

TABLE IV: Classification Report Strategi Terbaik (M9) pada Data Validasi (1 Sept – 30 Nov 2024)

Kategori	Precision	Recall	F1-Score	Support
SEDANG	0.95	0.90	0.92	298
TIDAK SEHAT	0.17	0.29	0.21	21
Accuracy		0.86		319
Macro avg	0.56	0.59	0.57	319
Weighted avg	0.90	0.86	0.88	319

1) Analisis Kualitatif:

- **Kategori SEDANG:** Tetap dominan dengan F1-Score 0.92, namun nilai *recall* (0.90) sedikit dikorbankan oleh mekanisme *adaptive threshold* demi meningkatkan sensitivitas terhadap kelas minoritas.
- **Kategori TIDAK SEHAT:** Terjadi peningkatan signifikan pada kemampuan deteksi kelas kritis ini. Pendekatan *Cross-Station Ensemble* (M9) berhasil memanfaatkan korelasi spasial antar stasiun pemantauan, sehingga sistem dapat memberikan peringatan dini yang lebih akurat dibandingkan model temporal murni.

D. Analisis Dinamika Spasial-Temporal

Selain metrik statistik, evaluasi visual dilakukan untuk memverifikasi kemampuan model dalam menangkap pola deret waktu di berbagai lokasi pemantauan. Gambar 8 menyajikan hasil *forecasting* model terbaik (Metode 9) untuk lima stasiun DKI Jakarta pada periode validasi.

Berdasarkan visualisasi tersebut, terdapat beberapa temuan kunci:

1) *Heterogenitas Spasial:* Meskipun tren umum antar stasiun terlihat sinkron (menunjukkan pengaruh faktor meteorologi regional yang kuat), terdapat perbedaan amplitudo yang signifikan.

- **DKI4:** Secara konsisten menunjukkan nilai prediksi ISPU tertinggi, dengan beberapa puncak mencapai indeks > 120 (TIDAK SEHAT). Hal ini mengindikasikan beban emisi lokal yang lebih tinggi di area tersebut dibanding stasiun lain, sesuai dengan temuan studi karakteristik partikulat di Jakarta [11].
- **DKI1 dan DKI3:** Menunjukkan profil yang relatif lebih rendah, namun tetap responsif terhadap fluktuasi harian.




Fig. 8: Detail Forecast ISPU per Stasiun pada Periode 1 September–30 November 2025

2) *Transisi Musiman (Seasonality):* Fitur paling menonjol pada Gambar 8 adalah penurunan tajam (*sharp decline*) tingkat polusi yang terjadi serentak di seluruh stasiun mulai awal November (sekitar tanggal 4 November).

Fenomena ini membuktikan bahwa fitur *Time Shift 11 Bulan* berhasil memberikan sinyal kepada model mengenai transisi musim kemarau ke musim hujan. Hujan berperan sebagai mekanisme *wash-out* (deposisi basah) yang efektif membersihkan polutan udara [12]. Kemampuan model untuk memprediksi penurunan drastis ini—meskipun hanya menggunakan data historis—menunjukkan bahwa pola musiman tahunan (“ulang tahun polusi”) terekam dengan baik oleh strategi *shifting* yang diusulkan.

E. Analisis Efektivitas Cross-Station Ensemble

Keunggulan performa metode M9 (*LGBM + Cross-Station Ensemble*) yang mencatat Macro F1 tertinggi (0.57) mengonfirmasi hipotesis bahwa polusi udara di Jakarta bukan sekadar fenomena lokal yang terisolasi, melainkan sistem regional yang saling terinterkoneksi.

Peningkatan akurasi ini dapat dijelaskan melalui tiga mekanisme utama yang dipelajari oleh model:

- 1) **Pemanfaatan Autokorelasi Spasial:** Berdasarkan Hukum Tobler (*First Law of Geography*) [13], lokasi yang berdekatan memiliki kemiripan karakteristik yang lebih tinggi dibandingkan lokasi yang berjauhan. Dengan menyertakan fitur historis dari stasiun tetangga, model M9 mendapatkan konteks regional yang lebih utuh. Hal ini membantu model membedakan antara tren polusi yang bersifat luas (misalnya akibat inversi suhu regional) dengan lonjakan yang bersifat lokal semata (misalnya pembakaran sampah di dekat satu sensor).
- 2) **Penangkapan Efek Transportasi Polutan (Adveksi):** Partikulat PM2.5 bersifat dinamis dan berpindah mengikuti arah angin. Peningkatan konsentrasi di satu stasiun sering kali menjadi sinyal awal (*early warning*) bagi stasiun lain yang berada di arah aliran angin (*downwind*). Strategi *Cross-Station* memungkinkan model mempelajari pola tunda (*lag*) pergerakan polusi antar-wilayah ini, sehingga prediksi menjadi lebih responsif dibandingkan model yang hanya melihat riwayat satu titik saja.
- 3) **Reduksi Noise dan Missing Data:** Sensor kualitas udara rentan terhadap gangguan teknis atau data kosong (*missing values*). Model *single-station* akan sangat menderita jika data historis stasiun tersebut "bolong" atau bernoise. Sebaliknya, pendekatan *ensemble* spasial memungkinkan model melakukan kompensasi informasi (interpolasi implisit) dengan merujuk pada data dari stasiun-stasiun lain yang masih berfungsi baik, menjadikan prediksi M9 lebih *robust* (tangguh).

V. ANALISIS FEATURE IMPORTANCE

Analisis *feature importance* dari model LightGBM mengungkap hierarki kontribusi fitur terhadap prediksi ISPU. Seperti terlihat pada Tabel V, fitur historis (Lag) dan klimatologis (Anchor) mendominasi model, diikuti oleh faktor meteorologi dinamis dan vegetasi.

TABLE V: Top 10 Feature Importance (LightGBM)

Feature	Importance (Score)
target_lag_1	938
target_lag_2	669
target_lag_3	634
anchor_clim_median	476
year	436
wind_gusts_10m_(km/h)_std	173
ndvi	171
apparent_temperature_(°C)_std	168
wind_speed_10m_y_std	158
wind_speed_10m_max_y_diff_lag_1	156

A. Dominasi Faktor Temporal

Fitur `target_lag_1`, `target_lag_2`, dan `target_lag_3` menempati peringkat teratas dengan skor kumulatif > 2200. Hal ini mengindikasikan bahwa ISPU memiliki sifat *autoregressive* yang sangat kuat, di mana kondisi udara hari sebelumnya adalah prediktor terbaik untuk hari esok.

Selain itu, `anchor_clim_median` (skor 476) berperan krusial sebagai *baseline* musiman, menjaga prediksi tetap berada dalam rentang wajar klimatologis tahunan agar tidak terjadi *drift* ekstrem pada horison prediksi yang panjang.

B. Pengaruh Faktor Meteorologi

Berbeda dengan asumsi konvensional yang berfokus pada nilai rata-rata (*mean*), model menemukan bahwa **variabilitas** (standar deviasi) dari parameter cuaca memiliki pengaruh lebih signifikan terhadap fluktuasi polusi.

1) *Dinamika Angin (Wind Gusts & Variability)*: Variabel `wind_gusts_10m_std` (skor 173) menjadi fitur meteorologi paling berpengaruh. Ini menunjukkan bahwa turbulensi atmosfer lebih berperan dalam dispersi polutan dibanding kecepatan angin rata-rata. Mekanisme fisik ini sejalan dengan teori difusi turbulen (K_z) [12]:

$$F = -K_z \frac{\partial C}{\partial z} \quad (12)$$

di mana fluks polutan vertikal (F) meningkat seiring tingginya turbulensi (*gustiness*), yang efektif memecah konsentrasi polutan di permukaan tanah.

2) *Apparent Temperature (Kenyamanan Termal)*: Fitur `apparent_temperature_std` (skor 168) muncul sebagai prediktor kunci. Tingginya variabilitas pada *apparent temperature* mengindikasikan ketidakstabilan atmosfer yang memengaruhi *mixing height*.

C. Pengaruh Vegetasi (NDVI)

NDVI (*Normalized Difference Vegetation Index*) memiliki skor importance 171, setara dengan faktor meteorologi utama. Ini memvalidasi hipotesis bahwa keberadaan ruang terbuka hijau (RTH) berfungsi sebagai penyaring alami melalui mekanisme deposisi kering [10]:

$$V_d = \frac{1}{R_a + R_b + R_c} \quad (13)$$

di mana V_d adalah kecepatan deposisi yang dipengaruhi oleh resistensi kanopi (R_c) dari vegetasi (NDVI).

D. Stabilitas Recursive Forecasting

Penggunaan `anchor_clim_median` terbukti berhasil menstabilkan performa model. Tanpa anchor, model *recursive* cenderung mengalami akumulasi error (*error propagation*) seiring bertambahnya hari prediksi, fenomena yang umum terjadi pada strategi peramalan multi-langkah [14], seperti ditunjukkan pada Tabel VI.

Hal ini mengonfirmasi bahwa pendekatan *hybrid* (Data Dinamis + Data Klimatologi) adalah strategi paling robust untuk prediksi jangka panjang.

TABLE VI: Dampak Anchor terhadap RMSE pada Horizon Berbeda

Horizon	RMSE (w/ Anchor)	RMSE (w/o Anchor)
Day 1-7	12.3	12.8
Day 8-30	15.7	22.4
Day 31-60	17.2	31.7

VI. KESIMPULAN

Penelitian ini berhasil mengembangkan kerangka kerja peramalan kualitas udara (ISPU) yang adaptif untuk wilayah DKI Jakarta. Temuan utama studi ini menegaskan bahwa akurasi prediksi polusi tidak hanya bergantung pada algoritma model, tetapi sangat ditentukan oleh kualitas dan rekayasa fitur data lingkungan. Kesimpulan spesifik yang diperoleh adalah:

- **Signifikansi Data Resolusi Tinggi dan NDVI:** Integrasi data meteorologi *hourly* (per jam) dari OpenMeteo dan indeks vegetasi (NDVI) terbukti memberikan kontribusi informasi yang krusial. NDVI berfungsi efektif sebagai proksi kapasitas penyerapan polutan alami (*natural sink*), sementara data cuaca per jam memungkinkan model menangkap dinamika mikroklimat yang sering hilang dalam data harian rata-rata.
- **Efektivitas Agregasi Statistik Intensif:** Strategi agregasi data cuaca yang dilakukan secara "brutal" atau komprehensif—dengan mengekstraksi nilai minimum, maksimum, standar deviasi, dan variabilitas intra-harian—terbukti vital. Pendekatan ini memungkinkan model untuk tidak hanya mempelajari nilai rata-rata parameter cuaca, tetapi juga volatilitas atmosfer (seperti *gustiness* angin dan fluktuasi suhu) yang menjadi determinan utama dalam proses dispersi polutan.
- **Superioritas Teknik *Lagging* dan *Shifting*:** Rekayasa fitur temporal melalui mekanisme *Time Lagging* dan *Seasonal Shifting* menjadi kunci utama performa model. Fitur *Lag* berhasil menangkap sifat autokorelasi jangka pendek (inersia polusi), sedangkan teknik *Shifting* (penggeseran waktu jangka panjang) sukses merekonstruksi pola musiman tahunan dan transisi musim hujan-kemarau tanpa memerlukan input kalender eksplisit. Kombinasi ini menjadikan model sangat robust dalam mengenali tren berulang.

Saran Pengembangan. Penelitian selanjutnya disarankan untuk mengintegrasikan variabel eksogen dinamis secara *real-time*, seperti data kepadatan lalu lintas dan titik panas kebakaran, guna meningkatkan responsivitas model terhadap lonjakan polusi non-meteorologis. Selain itu, eksplorasi arsitektur *Deep Learning* hibrida (seperti LSTM-Attention) direkomendasikan untuk meminimalisir propagasi galat pada prediksi jangka panjang (*recursive forecasting*) yang masih menjadi tantangan dalam studi ini.

ACKNOWLEDGMENT

Penulis mengucapkan terima kasih kepada penyelenggara Datavidia 10.0 atas penyediaan dataset komprehensif yang

memungkinkan penelitian ini, serta kepada Fakultas Ilmu Komputer Universitas Indonesia atas dukungan komputasi.

REFERENCES

- [1] Pemerintah Provinsi DKI Jakarta. (n.d.). Tentang Kualitas Udara Jakarta. Diakses pada 8 Februari 2026, dari <https://udara.jakarta.go.id/tentang>
- [2] IQAir. (n.d.). Air Quality in Jakarta, Indonesia. Diakses pada 8 Februari 2026, dari <https://www.iqair.com/id/indonesia/jakarta/jakarta>
- [3] Ayus, I., Natarajan, N., and Gupta, D. (2023). Comparison of machine learning and deep learning techniques for the prediction of air pollution: A case study from China. *Asian Journal of Atmospheric Environment*, 17(4). <https://doi.org/10.1007/s44273-023-00005-w>
- [4] Biancofiore, F., Busilacchio, M., Verdecchia, M., Tomassetti, B., Aruffo, E., Bianco, S., Di Tommaso, S., Colangeli, C., Rosatelli, G., and Di Carlo, P. (2017). Recursive neural network model for analysis and forecast of PM10 and PM2.5. *Atmospheric Pollution Research*, 8(4), 652–659. <https://doi.org/10.1016/j.apr.2016.12.014>
- [5] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- [6] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems 30 (NIPS 2017)*.
- [7] Norazian, M. N., Shukri, Y. A., Azam, R. N., and Bakri, A. M. M. A. (2008). Estimation of missing values in air pollution data using single imputation techniques. *ScienceAsia*, 34(3), 341–345. <https://doi.org/10.2306/scienceasia1513-1874.2008.34.341>
- [8] Sophia, A. V., Dinillah, F. I., and Mahfudzi, I. (2025). Klasifikasi indeks kualitas udara DKI Jakarta dengan multinomial logistic regression berbasis machine learning. *Jurnal Teknologi Maritim*, 8(2). <https://doi.org/10.35991/jtm.v8i2.80>
- [9] Lipton, Z. C., Elkan, C., and Naryanaswamy, B. (2014). Optimal thresholding of classifiers to maximize F1 measure. In *Joint European Conference on Machine Learning and Knowledge Discovery in Databases* (pp. 225–239). Springer. <https://arxiv.org/abs/1402.1892>
- [10] Nowak, D. J., Crane, D. E., and Stevens, J. C. (2006). Air pollution removal by urban trees and shrubs in the United States. *Urban Forestry & Urban Greening*, 4(3-4), 115–123. <https://www.sciencedirect.com/science/article/abs/pii/S1618866706000173>
- [11] Santoso, M., Lestiani, D. D., Kurniawati, S., Markwitz, A., and Hopke, P. K. (2020). Long-term variation of airborne particulate matter in Jakarta, Indonesia. *Atmospheric Pollution Research*, 11(12), 2215–2221. <https://ui.adsabs.harvard.edu/abs/2020AtmPR..11.2215S/abstract>
- [12] Seinfeld, J. H., and Pandis, S. N. (2016). *Atmospheric Chemistry and Physics: From Air Pollution to Climate Change* (3rd ed.). John Wiley & Sons.
- [13] Tobler, W. R. (1970). A computer movie simulating urban growth in the Detroit region. *Economic Geography*, 46(sup1), 234–240. https://dces.wisc.edu/wp-content/uploads/sites/128/2013/08/W5_Tobler1970.pdf
- [14] Taieb, S. B., Bontempi, G., Atiya, A. F., and Sorjamaa, A. (2012). A review and comparison of strategies for multi-step ahead time series forecasting based on the NN5 competition. *Expert Systems with Applications*, 39(8), 7067–7083. <https://arxiv.org/abs/1108.3259>